

# Machine learning y deep learning: Ética y Consideraciones Futuras en AI

Rolando Gonzales Martinez, PhD

Fellow postdoctoral Marie  
Skłodowska-Curie

Universidad de Groningen  
(Países Bajos)

Investigador (researcher)

Iniciativa de Pobreza y Desarrollo  
Humano de la Universidad de  
Oxford (UK)

# Etica en resultados de machine learning y deep learning

La **ética** estudia principios y valores que guían el comportamiento humano, distinguiendo entre lo que es correcto e incorrecto, bueno o malo, justo o injusto.

Principios:

- Moralidad: lo que es correcto en un contexto dado.
- Responsabilidad: rendir cuentas por las acciones y asumir las consecuencias de las mismas
- Justicia: equidad en el trato entre los individuos y en la distribución de los recursos, oportunidades y beneficios
- Autonomía: Se refiere al respeto por la capacidad de las personas para tomar decisiones por sí mismas
- Beneficencia y No Maleficencia: Estos principios promueven hacer el bien a los demás (beneficencia) y evitar causar daño innecesario (no maleficencia). En contextos como la medicina, estos principios son fundamentales para guiar la práctica profesional.

# Etica en resultados de machine learning y deep learning

Por ejemplo, responsabilidad (rendir cuentas por las acciones y asumir las consecuencias de las mismas)

**Gedankenexperiment 1:** una empresa paga a un científico de datos para construir un clasificador basado en machine learning (deep learning) para predecir si una persona tendrá o no tendrá cáncer. Cuando se aplica el algoritmo clasificador, una persona no recibe tratamiento temprano (porque tuvo un falso negativo) y llega a Stage 3.

¿Quién es responsable?

- ¿El científico de datos que diseñó y entreno el modelo?
- ¿La empresa que contrató al científico de datos?
- ¿El médico especialista que usó el clasificador MLDL para dar un diagnóstico?
- ¿El hospital que implementó el algoritmo clasificador para asistir las decisiones médicas?
- ¿El algoritmo clasificador MLDL?

# Ética en resultados de machine learning y deep learning

Justicia: equidad en el trato entre los individuos y en la distribución de los recursos, oportunidades y beneficios

Gedankenexperiment 2: un clasificador basado en machine learning (deep learning) creado para colocación de créditos, asigna menos créditos a personas debido a características como su género (sexo) o etnicidad.

¿Debería ser el deontologismo la teoría ética a aplicar en estos algoritmos? (i.e. las acciones son moralmente correctas o incorrectas basadas en el cumplimiento de normas o deberes, incluso si eso resulta en un modelo menos eficiente o más costoso de implementar)



**DHH** · Nov 7, 2019

@dhh · [Follow](#)

The @AppleCard is such a fucking sexist program. My wife and I filed joint tax returns, live in a community-property state, and have been married for a long time. Yet Apple's black box algorithm thinks I deserve 20x the credit limit she does. No appeals work.



**Steve Wozniak**

@stevewoz · [Follow](#)

The same thing happened to us. I got 10x the credit limit. We have no separate bank or credit card accounts or any separate assets. Hard to get to a human for a correction though. It's big tech in 2019.

1:51 AM · Nov 10, 2019



3.4K



Reply



Copy link

[Read 107 replies](#)

# Etica en resultados de machine learning y deep learning

Ethical biases of Artificial Intelligence in Algorithmic Lending:

- Bank D-Miro: micro-financial institution from Ecuador
- Ethnicity was approached with a measure of the regional location of the Montubios in Ecuador.

Table 1: Frequency of loan defaults by sex

sex	Loan default		
	no	yes	total
male	42038 (27)	24069 (16)	66107 (43)
female	59267 (39)	28289 (18)	87556 (57)
total	101305 (66)	52358 (34)	153663 (100)

Note: percentages in brackets below each frequency

Table 2: Descriptive statistics of the potential explanatory variables of loan default

Variable	Mean	Std. dev.	Min	Max
age	42.76	11.47	21	82
dependants	1.48	1.42	0	9
equity (thousands)	12.81	10.53	0	232.51
education	0.96	0.19	1	1
marital status (1 = single)	0.56	0.5	1	1
occupation	0.91	0.29	0	1
housing	0.64	0.48	0	1
wife contributes to paying the loan (=1)	0.07	0.26	0	1
balance	0.01	1.99	-1.75	57.90
flow	-0.14	1.56	-2.36	30.19

Note: Total number of observations  $n = 153663$

# Etica en resultados de machine learning y deep learning

Lending algorithms (machine learning models)	Overall results	Equality		Inclusion	
		Women	Men	Ethnic women	Ethnic & poor women
Area under the curve (AUC)					
Passive-aggressive algorithm	50.9	50.6	51.3	51.4	51.0
Stochastic vector machine	54.1	53.9	54.7	52.9	53.5
Logistic classification	55.6	55.5	55.7	63.2	64.7
Elastic net	58.4	57.8	59.1	63.0	62.6
Neural network	59.5	59.5	59.4	68.6	69.9
Stochastic gradient classifier	60.6	58.6	63.3	60.5	61.5
Random forest	92.6	92.6	92.6	91.5	91.8
Gradient boosting (XGBoost)	92.9	93.0	92.7	91.7	92.2
Exclusion errors					
Logistic classification	85.9	86.5	85.2	69.5	67.3
Neural network	74.7	75.0	74.2	54.5	52.5
Stochastic gradient classifier	39.0	41.2	36.4	37.1	35.5
Elastic net	39.0	38.4	39.6	20.8	20.5
Stochastic vector machine	8.5	6.4	11.1	6.0	5.0
Random forest	7.4	7.9	6.7	6.6	6.4
Gradient boosting (XGBoost)	6.9	7.3	6.4	5.9	5.6
Passive-aggressive algorithm	2.2	2.5	1.9	1.5	1.6

(\*) Balanced sample: percentage of men is equal to the percentage of women.  
Ethnic and poor women are women living in poor regions.

Lending algorithms (machine learning models)	Overall results	Equality		Inclusion	
		Women	Men	Ethnic women	Ethnic & poor women
Area under the curve (AUC)					
Passive-aggressive algorithm	55.8	56.2	55.8	64.4	64.7
Elastic net	58.9	58.4	59.0	64.6	65.0
Stochastic gradient classifier	59.2	58.7	59.2	69.8	71.3
Logistic classification	59.9	59.9	59.9	70.6	72.7
Stochastic vector machine	61.5	62.1	61.5	69.0	69.7
Neural network	63.9	60.9	64.4	65.7	66.8
Random forest	91.5	82.0	92.5	88.9	90.0
Gradient boosting (XGBoost)	91.8	82.1	92.9	87.4	89.1
Exclusion errors					
Passive-aggressive algorithm	83.7	82.5	83.8	64.5	64.5
Stochastic gradient classifier	73.8	74.5	73.8	49.7	46.1
Logistic classification	71.3	72.2	71.2	49.7	45.4
Stochastic vector machine	58.3	53.0	59.0	29.7	27.0
Neural network	43.9	45.3	43.7	29.7	25.5
Elastic net	38.6	37.5	38.8	18.7	17.0
Random forest	9.1	29.7	6.7	18.1	14.9
Gradient boosting (XGBoost)	8.4	29.9	6.0	19.4	15.6

Imbalanced sample: percentage of men is higher than the percentage of women.  
Ethnic and poor women are women living in poor regions.

# Etica en resultados de machine learning y deep learning

- Métricas de desempeño: paridad demográfica (tasa de resultados positivos igual entre diferentes grupos)
- Algoritmos realizan ajustes durante el preprocesamiento, durante el entrenamiento, o durante el post-procesamiento: imbalanced-learning, AIF360, Fairlearn.

## **AIF360 (AI Fairness 360):**

- Desarrollada por IBM, es una de las bibliotecas más completas para abordar la discriminación en machine learning. Incluye herramientas para preprocesamiento, inprocesamiento y posprocesamiento.
- Incluye algoritmos para reducir el sesgo y métricas para evaluar la equidad.

## **Fairlearn**

- Fairlearn es una biblioteca de Microsoft que proporciona herramientas para evaluar y mitigar el sesgo en modelos de machine learning.
- Incluye técnicas para ajustar los modelos y garantizar que cumplan con criterios de equidad.

# Ética en resultados de machine learning y deep learning

FAHT (Fairness-Aware Hyperplane Tree: árbol hiperplano consciente de la equidad) clasificador de árbol de decisión diseñado para abordar cuestiones de equidad en tareas de clasificación y regresión.

- Restricciones de imparcialidad en el árbol de decisión: reduce el potencial de resultados sesgados y promueve decisiones más equitativas entre los grupos sensibles.
- Incluye métricas de equidad: paridad demográfica, las probabilidades igualadas u otros criterios de equidad.
- División basada en hiperplanos para permitir límites de decisión más flexibles y complejos

$$P(\hat{Y} = 1|S = 1) = P(\hat{Y} = 1|S = 0)$$

$$\min_{\theta} \mathcal{L}(\theta, X, Y) + \lambda \mathcal{F}(\theta, S)$$

$$h(X) = w_1x_1 + w_2x_2 + \dots + w_dx_d$$

$$X = (x_1, x_2, \dots, x_d)$$

$$\min_w [\mathcal{I}(w) + \lambda \mathcal{F}(w, S)]$$

$$w_t \leftarrow w_{t-1} - \eta \nabla_w [\mathcal{L}(w_{t-1}, X_t, Y_t) + \lambda \mathcal{F}(w_{t-1}, S_t)]$$



# Spatial machine learning


Indonesian socioeconomic survey data - the Social Surveys National Economy (SUSENAS)

Que hogares deben recibir transferencias para reducir la pobreza?

$$EE = \frac{fn}{tp + fn}$$

$$IE = \frac{fp}{tp + fp}$$

Figure 4: Results of the Principal Component Analysis (PCA) applied to the SUSENAS data 2016 to 2020



# Spatial machine learning

Figure 5: Spatial contiguity by region (kabupaten)



# Spatial machine learning

Figure 13: Spatial hierarchical clustering and dendrogram: 12 clusters



# Spatial machine learning

$$EE = \frac{fn}{tp + fn}$$

$$IE = \frac{fp}{tp + fp}$$

		Benchmark ML models*	Spatial machine learning models					
			Without principal component analysis			With principal component analysis		
			4 clusters	6 custers	12 clusters	4 clusters	6 custers	12 clusters
Exclusion error								
Elastic net	28.50	28.42	28.39	28.28	28.47	28.46	28.38	
Gradient boosting	31.48	28.79	28.74	28.53	30.99	30.97	30.93	
Linear regression	28.20	28.20	28.22	28.15	28.22	28.25	28.19	
Logistic classification	33.25	27.53	27.44	30.49	33.25	33.15	33.93	
Naive Bayes	28.77	20.44	20.40	20.14	22.90	23.17	23.05	
Neural network	30.60	34.19	35.23	35.69	32.08	29.66	31.77	
Random forest	57.19	45.72	45.86	45.36	53.65	54.01	54.06	
Stochastic gradient	35.02	58.53	58.97	57.86	56.49	56.02	56.28	
Inclusion error								
Elastic net	28.49	32.39	32.57	32.26	32.43	32.59	32.34	
Gradient boosting	31.47	32.59	32.77	32.41	34.56	34.75	34.54	
Linear regression	28.20	32.18	32.35	32.13	32.21	32.38	32.17	
Logistic classification	27.36	46.28	46.40	45.56	37.35	36.72	35.05	
Naive Bayes	43.54	43.28	43.60	43.54	43.90	43.89	43.89	
Neural network	28.85	57.17	57.41	57.80	46.06	44.53	41.66	
Random forest	33.52	28.97	29.63	29.36	32.29	32.89	32.20	
Stochastic gradient	41.10	52.53	53.18	52.39	45.92	44.31	43.87	
Minimum values								
Exclusion error (EE)	28.20	20.44	20.40	20.14	22.90	23.17	23.05	
Inclusion error (IE)	27.36	28.97	29.63	29.36	32.21	32.38	32.17	

# Inteligencia artificial bionica

No es equivalente a la ingeniería biónica, pero está relacionada:

- Algoritmos genéticos
- Inteligencia artificial bio-inspirada:
  - Redes neuronales líquidas
  - Ant Colony Optimization (ACO)
  - Redes Neuronales de Espigas (Spiking Neural Networks, SNN)
  - ...

# Redes Neuronales Liquidas

- RNL fueron inspiradas por el nematodo microscópico, *Caenorhabditis elegans*, que tiene 302 neuronas en su sistema nervioso
- Hasani codificó su red neuronal prestando especial atención a cómo las neuronas de *C. elegans* se activan y se comunican entre sí mediante impulsos eléctricos. En las ecuaciones que utilizó para estructurar su red neuronal, permitió que los parámetros cambien con el tiempo según los resultados de un conjunto anidado de ecuaciones diferenciales.





# Redes Neuronales Liquidas



---

**Algorithm 1** LTC update by fused ODE Solver

---

**Parameters:**  $\theta = \{\tau^{(N \times 1)} = \text{time-constant}, \gamma^{(M \times N)} = \text{weights}, \gamma_r^{(N \times N)} = \text{recurrent weights}, \mu^{(N \times 1)} = \text{biases}\}$ ,  $A^{(N \times 1)} = \text{bias vector}$ ,  $L = \text{Number of unfolding steps}$ ,  $\Delta t = \text{step size}$ ,  $N = \text{Number of neurons}$ ,

**Inputs:**  $M$ -dimensional Input  $\mathbf{I}(t)$  of length  $T$ ,  $\mathbf{x}(0)$

**Output:** Next LTC neural state  $\mathbf{x}_{t+\Delta t}$

**Function:** FusedStep( $\mathbf{x}(t)$ ,  $\mathbf{I}(t)$ ,  $\Delta t$ ,  $\theta$ )

$$\mathbf{x}(t + \Delta t)^{(N \times T)} = \frac{\mathbf{x}(t) + \Delta t f(\mathbf{x}(t), \mathbf{I}(t), t, \theta) \odot A}{1 + \Delta t (1/\tau + f(\mathbf{x}(t), \mathbf{I}(t), t, \theta))}$$

▷  $f(\cdot)$ , and all divisions are applied element-wise.

▷  $\odot$  is the Hadamard product.

**end Function**

$\mathbf{x}_{t+\Delta t} = \mathbf{x}(t)$

**for**  $i = 1 \dots L$  **do**

$\mathbf{x}_{t+\Delta t} = \text{FusedStep}(\mathbf{x}(t), \mathbf{I}(t), \Delta t, \theta)$


**end for**

**return**  $\mathbf{x}_{t+\Delta t}$

---

# Inteligencia artificial tentacular


- Sistemas de IA distribuidos y multi-agente, capaces de actuar a través de Internet de las Cosas (IoT) y el edge computing.
- Funcionan de manera autónoma, colaborando entre agentes para resolver problemas complejos, con capacidad de tomar decisiones éticas y legales.
- Acciones Distribuidas: La IA puede delegar tareas a otros agentes o sistemas, extendiendo su "tentáculos" a través de redes globales, IoT, y ciberespacios.





# Inteligencia artificial tentacular

- Justificación y Transparencia: Cada decisión tomada por un agente TAI debe ser acompañada de una explicación y prueba de que es ética y segura.
- Cálculo de Eventos Cognitivos Deónticos (DCEC): Permite representar obligaciones, permisos y prohibiciones en la toma de decisiones de los agentes (e.g., "el agente debe encender la luz si detecta movimiento").



# Spiking Neural Networks (SNN)

Spiking Neural Networks: redes neuronales que intentan imitar más de cerca el comportamiento biológico de las neuronas.

SNN funcionan con pulsos discretos llamados spikes o impulsos.

Tercera generación de modelos de redes neuronales:

1. Primera generacion: perceptron, perceptron multicapa
2. Segunda generación: funciones de activación no-lineales y deep learning
3. Tercera generacion: SNN y computación neuromórfica

# RNA y deep learning **no son** modelos del cerebro humano

- RNA y DL están inspirados en el funcionamiento del cerebro, pero no buscan replicarlo o emularlo.
- Proyectos que buscan emular el cerebro humano: El proyecto de neurociencia EBRAINS de la Comisión Europea.

Un proyecto de  
EBRAINS: **Virtual Brain  
Twin** para el tratamiento  
personalizado de  
Trastornos Psiquiátricos




eBRAIN-Health

*Europe spent €600 million to recreate the human brain in a computer. How did it go?*


**Nature, 22 de Agosto**

<https://www.nature.com/articles/d41586-023-02600-x>



Reconstrucción digital de un circuito de neuronas del lóbulo temporal de un cerebro humano


# Sistema visual de los seres humanos



¿Perro?

¿Gato?

# Sistema visual de los seres humanos



<https://www.ndtv.com/offbeat/hilarious-video-shows-cat-that-looks-like-a-dog-until-it-suddenly-moves-2690289>

# Sistema visual de la inteligencia artificial

- Para enseñar a un algoritmo cómo reconocer objetos en imágenes, se entrena un algoritmo con millones de imágenes
- Se utiliza un tipo específico de red neuronal artificial: una **red neuronal convolucional profunda**.
- Su nombre proviene de una de las operaciones más importantes de la red: la **convolución**.



08	02	22	97	38	15	00	40	00	75	04	05	07	78	52	12	50	77	37	24
49	49	99	40	17	81	18	57	60	87	17	40	98	43	68	68	04	56	42	00
81	49	31	73	55	79	14	29	93	71	40	47	58	58	30	03	49	13	36	65
52	70	95	23	04	60	11	42	69	44	88	56	01	32	56	71	37	02	36	91
22	31	16	71	51	67	85	89	41	92	36	54	22	40	40	28	66	33	13	80
24	47	31	00	99	03	45	02	44	75	33	53	78	36	84	20	35	17	12	50
32	98	81	28	64	23	67	10	26	38	40	67	59	54	70	66	18	38	64	70
67	26	20	68	02	62	12	20	95	63	94	39	63	08	40	91	66	49	94	21
24	55	58	05	66	73	99	26	97	17	78	78	96	83	14	88	34	89	63	72
21	36	23	09	75	00	76	44	20	45	35	14	00	61	33	97	34	31	33	95
78	17	53	28	22	75	31	67	15	94	03	80	04	62	16	14	09	53	56	92
16	39	05	42	96	35	31	47	55	58	88	24	00	17	54	24	36	29	85	57
86	56	00	48	35	71	89	07	05	44	44	37	44	60	21	58	51	54	17	58
19	80	81	68	05	94	47	69	28	73	92	13	86	52	17	77	04	89	55	60
04	52	08	83	97	35	99	16	07	97	57	32	16	26	26	79	33	27	98	66
88	34	68	87	57	62	20	72	03	46	33	67	46	55	12	32	63	93	53	69
04	42	16	73	35	65	33	11	24	94	72	18	08	46	29	32	40	62	76	36
20	69	36	41	72	30	23	88	34	45	83	49	82	67	59	85	74	04	36	16
20	73	35	29	78	31	90	01	74	31	49	71	48	04	41	16	23	57	05	54
01	70	54	71	83	51	54	69	16	92	33	48	61	43	52	01	89	23	67	88

lo que ve la inteligencia artificial

clasificación de la imagen

82% gato  
15% perro  
2% oso  
1% planta




# Computación en GPU

La computación en GPU (Unidad de Procesamiento Gráfico, por sus siglas en inglés) se refiere al uso de las unidades de procesamiento gráfico que normalmente se encuentran en tarjetas gráficas para realizar cálculos y tareas de procesamiento más allá de la representación y renderización de gráficos.

Las GPUs están diseñadas originalmente para manejar cálculos relacionados con gráficos en videojuegos, visualización 3D y otras aplicaciones gráficas intensivas. Sin embargo, debido a su arquitectura altamente paralela, también son capaces de realizar cálculos numéricos y científicos de manera muy eficiente.

La computación en GPU ha ganado popularidad en áreas que involucran cálculos intensivos, como la simulación científica, el aprendizaje profundo (deep learning), la minería de criptomonedas, la investigación biomédica, la ingeniería y más. Aquí hay algunos puntos clave sobre la computación en GPU




# Computación en GPU

**Arquitectura paralela:** Las GPUs están compuestas por un gran número de núcleos pequeños y eficientes que trabajan en paralelo.

**Alto rendimiento:** Debido a su arquitectura paralela, las GPUs pueden lograr un rendimiento significativamente mayor en comparación con las CPU para ciertos tipos de cálculos. Esto es especialmente notable en tareas que implican grandes cantidades de datos o cálculos matriciales, como en el aprendizaje profundo.

**Programación especializada:** Aunque las GPUs pueden usarse para cálculos genéricos, a menudo se requiere una programación especializada para aprovechar al máximo su potencial. Lenguajes y bibliotecas como CUDA (Compute Unified Device Architecture) de NVIDIA permiten a los desarrolladores escribir códigos que se ejecuten directamente en la GPU.

**Clusters de GPU:** En algunas aplicaciones, múltiples GPUs se combinan en clústeres para crear supercomputadoras especializadas.






# SNN para clasificar imagenes de cáncer de mama

Low  
accuracy  
(~53%),  
low  
detection

Input (train sample)



Ground Truth




SNN result



Input (train sample)



Ground Truth




SNN result




# SNN para clasificar imagenes de cáncer de mama

High  
accuracy  
(~79%),  
low  
detection


Input (train sample)




Ground Truth




SNN result



Input (train sample)



Ground Truth



SNN result




# SNN para clasificar imagenes de cáncer de mama

Low  
accuracy  
(~43%),  
better  
detection

Input (train sample)



Ground Truth




SNN result



Input (train sample)



Ground Truth




SNN result



# Computación neuromórfica

SNN se puede implementar como software, pero también como hardware:

- En el hardware neuromórfico, los cálculos son realizados por muchas unidades pequeñas que se comunican entre sí a través de ráfagas de actividad (picos, spikes) y ajustan su comportamiento en función de los picos que reciben de otros.
- Modelizado a partir de los sistemas del cerebro y el sistema nervioso humanos.



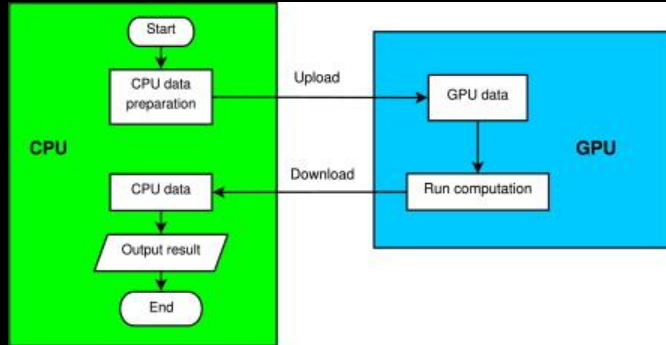
# Computación neuromórfica

SNN se puede implementar como software, pero tambien como hardware:

- Pueden formar una computadora cognitiva que conecta inteligencia artificial y algoritmos de aprendizaje automático en un circuito integrado que reproduce fielmente el comportamiento del cerebro humano.



# GPU computing en MatLab



The image shows the MATLAB environment. The Editor window displays a script with the following code:

```
16 IPC_t0 = 115; % IPC observado
17 % Initialize GPU
18 gpuDevice(1)
19 % -----
20 % Agente 1:
21 % Transfiriendo datos a GPU: agente 1
22 inflacion_esperada = gpuArray(...
23     rd_neuronal(inflacion_observada_al, parametros_al) + ...
24     rand()*randi([-1,1],PEA/3,1)...
25 );
26 IPC_t1 = IPC_t0*(1 + inflacion_esperada/100);
27 salario_real = (salario_nominal./IPC_t1)*100 + rand()*randi([-500,2e3],1);
28 shabilidades = 0.10;
```

The Command Window shows the output of the `gpuDevice(1)` command:

```
ans =
    CUDADevice with properties:

        Name: 'NVIDIA GeForce RTX 2060'
        Index: 1
    ComputeCapability: '7.5'
    SupportsEcc:
        DriverVersion: 12
        ToolkitVersion: 11
```

# Aplicaciones

Inflación es un  
“impuesto” a los  
pobres por sus  
efectos  
asimétricos,  
aumentando la  
desigualdad

The current issue and full text archive of this journal is available on Emerald Insight at:  
[www.emeraldinsight.com/2040-0705.htm](http://www.emeraldinsight.com/2040-0705.htm)

AJEMS  
10,2

226

Received 8 October 2018  
Revised 22 January 2019  
Accepted 4 February 2019

## Inflation shocks and income inequality

### An analysis with genetic algorithms and Bayesian quantile regressions

Rolando Gonzales

*Universitetet i Agder, Kristiansand, Norway, and*

Andrea Rojas-Hosse

*University College London, London, UK*

#### Abstract

**Purpose** – The purpose of this paper is to analyze the effects of inflationary shocks on inequality, using data of selected countries of the Middle East and North Africa (MENA).

**Design/methodology/approach** – Inflationary shocks were measured as deviations from core inflation, based on a genetic algorithm. Bayesian quantile regression was used to estimate the impact of inflationary shocks in different levels of inequality.

**Findings** – The results showed that inflationary shocks substantially affect countries with higher levels of inequality, thus suggesting that the detrimental impact of inflation is exacerbated by the high division of classes in a country.

**Originality/value** – The study contributes to the literature about the relationship between inflation and inequality by proposing that not only the sustained increase in prices but also the inflationary shocks – the deviations from core inflation – contribute to the generation of inequality. Also, to the best of the authors knowledge, the relationship between inflation shocks and inequality in the MENA region has never been analyzed before, thus creating a research gap to provide additional empirical evidence about the sources of inequality. Additionally, the authors contribute with a methodological approach to measure inflationary shocks, based on a semelparous genetic algorithm.

**Keywords** Bayesian methods, MENA region, Inflation and inequality

**Paper type** Research paper



# Aplicaciones

- Una especie es considerada semélpara si se caracteriza por tener un único episodio reproductivo antes de morir
- Algoritmos genéticos semélparos se utilizan para estimar los parámetros óptimos de un filtro de reducción de ruido (estimación de la inflación núcleo).

## Box 1. Semelparous genetic algorithm based on the behavior of the *Octopus Mimus*.

Genesis:

1. In  $g = 0$ , a population  $i = 1, 2, \dots, p$  is created, with  $\lambda_{g,i}^a \sim \mathcal{U}(\cdot)$ ,  $\lambda_{g,i}^b \sim \mathcal{U}(\cdot)$
2.  $\mathbf{x}_i^c = \pi - \pi_\omega - \mathbf{t}_\omega [(\mathbf{t}'_\omega \mathbf{t}_\omega)^{-1} \mathbf{t}'_\omega \pi_\omega]$  is estimated,
3.  $\delta_{\pi,i}$  is calculated,

Natural selection:

4.  $\delta_{\pi,i}$  is sorted ( $\delta_{\pi,(1)} \leq \delta_{\pi,(2)} \leq \dots \leq \delta_{\pi,(p)}$ ). Then,  $(1-d)p$  ( $0 < d < 1$ ) individuals are selected, with  $\lambda_{g,(j)}^a$  and  $\lambda_{g,(j)}^b$  ( $j = 1, 2, \dots, (1-d)p$ ) of  $p$ ,  $\delta_{\pi,(1)} \leq \delta_{\pi,(2)} \leq \dots \leq \delta_{\pi,(1-d)p}$


Evolution (mutation):

5. Given  $\theta \sim \mathcal{B}(\cdot, \cdot)$ ,  $\varpi \in [0, 1]$  and  $m_i \sim \mathcal{N}(0, 1)$ ,  
 $\lambda_{g+1,i}^a = \theta \lambda_{g,i}^a + (1-\theta) \lambda_{g,i}^b + \varpi m_i$ ,  
 $\lambda_{g+1,i}^b = \theta \lambda_{g,i}^b + (1-\theta) \lambda_{g,i}^a + \varpi m_i$ .
6. Steps 2 to 5 are repeated during  $g = 0, 1, \dots, j$ -generations.

AJEMS  
10,2

232

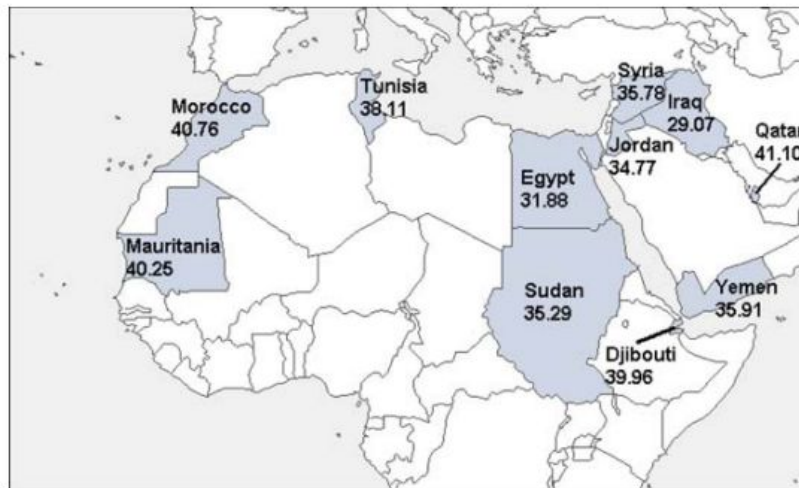
Plate 1.  
*Octopus mimus*  
illustration from the  
book *Molluscs and  
Shells* (1852-1856) of  
Augustus Addison  
Gould





# Aplicaciones


Datos de inflación y  
desigualdad  
medida por el  
coeficiente de Gini



Inflation  
shocks and  
income  
inequality

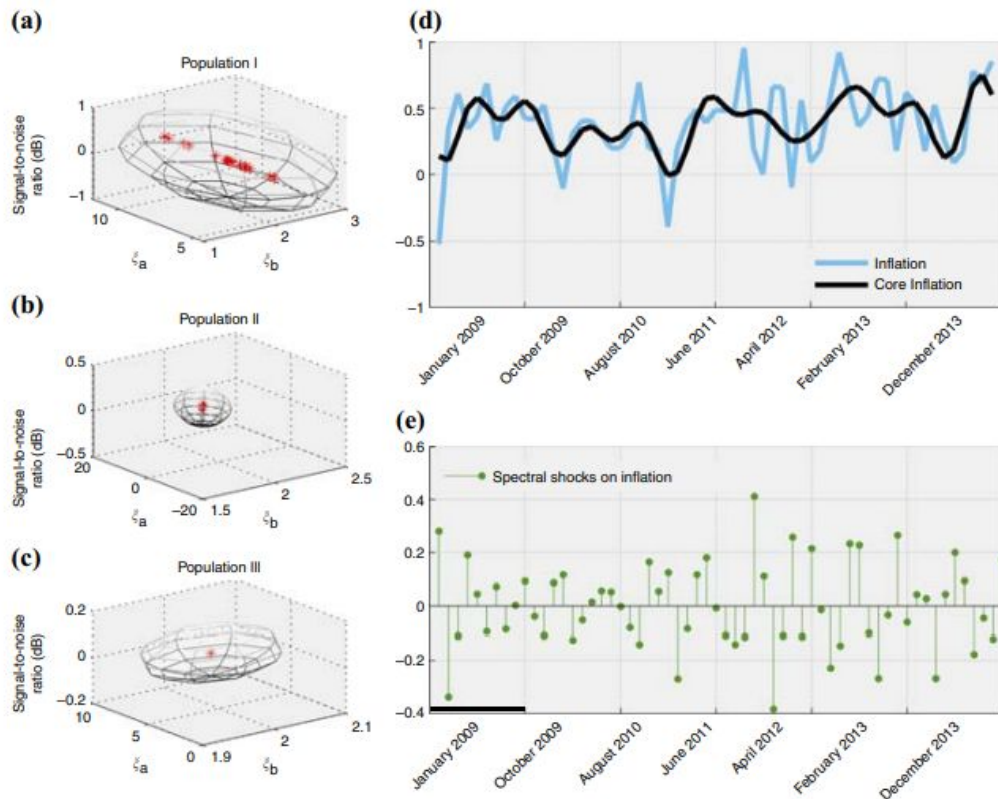
233

**Figure 1.**  
Gini coefficient  
in selected  
MENA countries



**Figure 2.**  
Consumer price  
index in selected  
MENA countries

# Aplicaciones



**Figure 3.**  
Tunisia: estimation  
of core inflation with  
SGA and deviations  
in prices

shocks in prices ( $\sigma_{\hat{\pi}}$ )


# Aplicaciones

$$\min_{(u,v,\beta) \in \mathbb{R}^p \times \mathbb{R}_+^{2n}} \{p1'_n u + (1-p)1'_n v \mid \mathbf{X}'_i \beta_p + u - v = y\},$$

$$f(y|\beta_p, z) \propto \left(\prod_{i=1}^n z_i^{-1/2}\right) \exp\left\{-\sum_{i=1}^n \frac{(y_i - \mathbf{X}'_i \beta_p - \theta z_i)^2}{2\tau^2 z_i}\right\}$$

$$\hat{\beta}_p = \hat{\mathbf{B}}_p \left\{ \sum_{i=1}^n \frac{\mathbf{X}_i (y_i - \theta z_i)}{\tau^2 z_i} + \mathbf{B}_{p0}^{-1} \beta_{p0} \right\},$$

- Debajo del decil 5 los intervalos de credibilidad Bayesiana empiezan a cruzar cero: países con una desigualdad menor a 0.36 (países con mayor igualdad), tienen menos efectos de inequidad causados por la inflación



# Aplicaciones

## Optimización con algoritmos basados en colonias de hormigas

### Balancing Input-Output tables with Bayesian slave-raiding ants

Rolando Gonzales Martínez

*Bayesian Institute for Research & Development, La Paz, Bolivia*

*E-mail: rgonzales@bayesgroup.org*

**Abstract.** Input-Output (I-O) tables are produced by statistical offices to estimate the relationships between the sectors of an economy. I-O tables can be unbalanced if the sum of its columns (total input destination) does not equal the sum of its rows (total output). An artificial Ant Colony (ACO) algorithm based on Bayesian slave-making polymorphous ants is proposed for balancing an I-O matrix. The approach is inspired on the behavior of *Rossomyrmex minuchae*, a parasite ant that enslaves other species of ants (*Proformica*) which in turn choose an optimal path between their colony and the source of food by leaving a trace of pheromones. In the algorithm, an improvement in the balance of I-O accounts increase the pheromones, thus raising the probability of ants moving towards the equilibrium of the matrix. An application to a real I-O matrix and Monte Carlo experiments were performed to evaluate the proposed ACO algorithm. The results showed that slave-raiding ACO can be used by statistical offices as an automated algorithm to produce more timely and reliable I-O tables.

Keywords: Input-Output models, artificial Ant Colony optimization, Bayesian analysis

**JEL codes:** C67, C61, C11


# Aplicaciones

Optimización con  
algoritmos basados en  
colonias de hormigas



Fig. 2. *Proformica ferreri* (top) and *Rossomyrmex minuchae* (bot-  
tom)

R. Gonzales Martínez / Balancing Input-Output tables with Bayesian slave-raiding ants



# Aplicaciones

## Optimización con algoritmos basados en colonias de hormigas

### Box 1: Slave-raiding ACO algorithm

#### Step 1 (Slave-raiding )

##### 1.1. Optimal number of ants

while  $p_{s,s+1} = 1$

$\delta \leftarrow \delta_0 + 1$

$s \leftarrow s_0 \exp(\delta)$

$\{d_k\}_{k=1}^s = f(\phi_0, s)$

$$p_{s,s+1}(\{d_k\}_{k=1}^{s_0}) = \frac{\sqrt{\pi} \left(\frac{s-1}{2}\right)^{r/2}}{\sqrt{\pi} \left(\frac{s-1}{2}\right)^{r/2} + \left(\frac{1+F}{s-1}\right)^{(s/2-1)}},$$

##### 1.2. Optimal size of ants (polymorphism)

while  $p_{s,s+1} \geq \text{epsilon}$

$\sigma \leftarrow \sigma_0 + 1$

$\phi \leftarrow \phi_0 \exp(\sigma)$

$\{d_k\}_{k=1}^s = f(\phi, s)$

$$p_{s,s+1}(\{d_k\}_{k=1}^s) = \frac{\sqrt{\pi} \left(\frac{s-1}{2}\right)^{r/2}}{\sqrt{\pi} \left(\frac{s-1}{2}\right)^{r/2} + \left(\frac{1+F}{s-1}\right)^{(s/2-1)}},$$

#### Step 2

For an optimal  $\phi$  and optimal 1, 2, ..., s-iterations:

- i. If  $\theta^{(s+1)} \leq \theta^{(s)}$ , then,  
 $\mathbf{M}^{(s+1)} \leftarrow \mathbf{M}^{(s)}$  and  $\theta^{(s+1)} \leftarrow \theta^{(s)}$
- ii. If  $\theta^{(s+1)} > \theta^{(s)}$ , but  $p(x|\alpha, \beta) > \omega, \omega \sim U(0, 1)$   
 $\mathbf{M}^{(s+1)} \leftarrow \{\lambda \mathbf{M}^{(s)} + (1 - \lambda) \mathbf{M}^{(s)}\}, < \lambda < 1,$   
 $\phi^{(s+1)} \leftarrow (1 + \varrho) \phi^{(s)} 0 \leq \varrho < 1$



# Aplicaciones


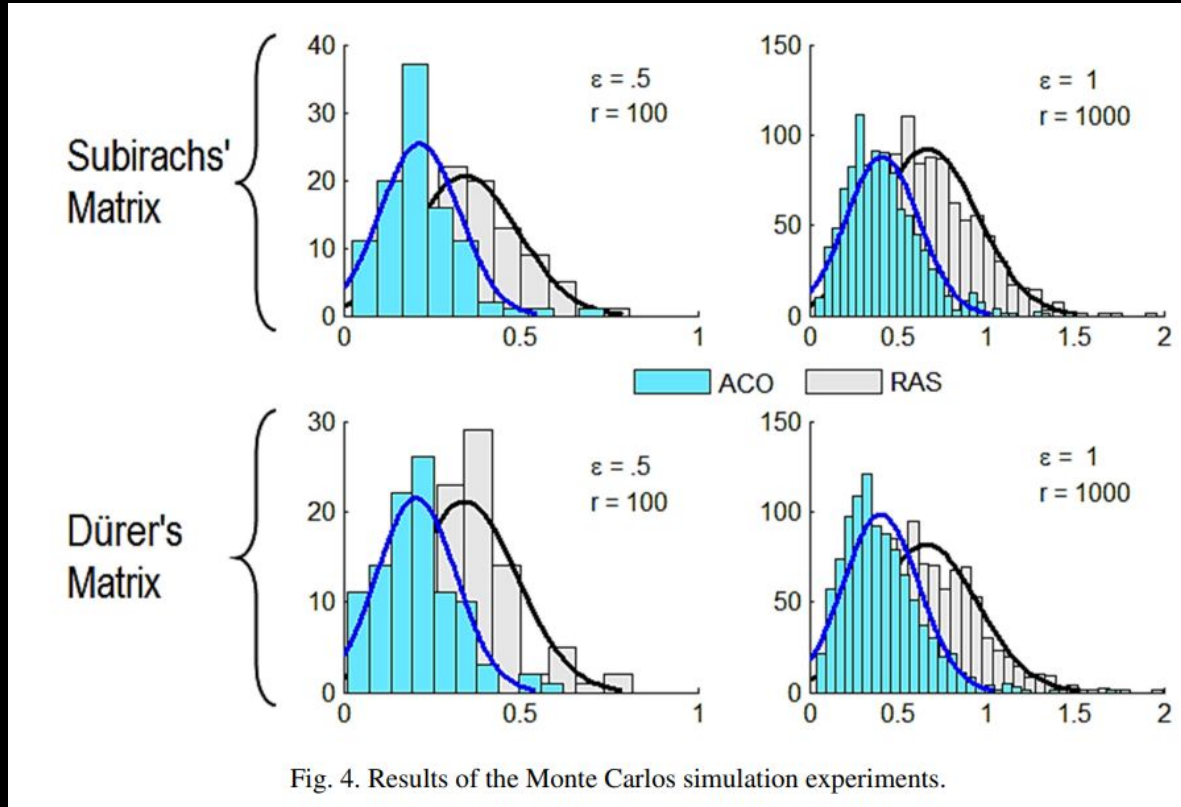


Fig. 3. Subirachs Magic Square (right) and Dürer's Magic Square (left).

# Aplicaciones





# Links a tesis de maestría en ciencia de datos

<https://openresearch.amsterdam/en/page/88292/master-theses---data-science-artificial-intelligence>

Veamos un par de tesis y su estructura